UNIVERSIDADE POSITIVO

Análise e Desenvolvimento de Sistemas

DATA SCIENCE — TRABALHO A2

Classificação binária em três domínios e análise de pontos de corte

SMS Spam · Bank Marketing · Breast Cancer Wisconsin

EQUIPE

Ana Julia Bernardino Klenk	RGM 43455301
André Felipe Lima de Almeida	RGM 42970253
João Pedro Galdino e Silva	RGM 42661315
Thiago Kauan Cardozo da Silva	RGM 43725694

PROFESSOR(A)

Ricardo Camati

São José dos Pinhais · 2026

Resumo

Três bases do UCI (SMS Spam, Bank Marketing e Breast Cancer Wisconsin) foram modeladas com o mesmo notebook. Os melhores modelos, escolhidos pelo F1 na validação cruzada, atingiram F1 de 0,893, 0,346 e 0,961 no teste. Com dois pontos de corte escolhidos na validação, 84% das mensagens e 88% dos exames são decididos automaticamente com erro abaixo de 2%. No bank, o sinal fraco limita a triagem automática a 14% dos clientes.

SMS Spam

a mensagem é spam?

0,893

F1 no teste · Random Forest

83,60% decididos automaticamente
(t1 / t2 = 0,38 / 0,50)

AUC-ROC	0,983
Positivos na faixa neg.	1,84% (3/163)
Negativos na faixa pos.	0,71% (8/1.130)

Bank Marketing

o cliente vai aderir ao depósito a prazo?

0,346

F1 no teste · Random Forest

13,97% decididos automaticamente
(t1 / t2 = 0,16 / 0,56)

AUC-ROC	0,742
Positivos na faixa neg.	0,77% (1/130)
Negativos na faixa pos.	6,69% (67/1.001)

Breast Cancer

o tumor é maligno?

0,961

F1 no teste · SVM (RBF)

88,12% decididos automaticamente
(t1 / t2 = 0,06 / 0,68)

AUC-ROC	0,995
Positivos na faixa neg.	1,89% (1/53)
Negativos na faixa pos.	0,00% (0/90)

Barra: parcela do conjunto de teste decidida automaticamente (faixas negativa e positiva); o restante vai para análise manual. Todos os números vêm do conjunto de teste, com os cortes escolhidos na validação.

Palavras-chave: classificação binária; validação cruzada; F1-score; SHAP; pontos de corte.

Sumário

1. Bases de dados 4

2. Programa da Parte 1 — histograma e faixas de decisão 5

3. Metodologia 6

3.1 Balanceamento e escolha da métrica principal 6

3.2 Separação dos dados e validação 6

3.3 Pré-processamento e representação 6

3.4 Algoritmos e otimização de hiperparâmetros 7

3.5 Avaliação no teste e construção das curvas 7

3.6 Explicação com SHAP 7

3.7 Escolha dos pontos de corte 8

4. Resultados — SMS Spam 9

4.1 Comparação dos modelos 9

4.2 Melhor modelo no teste 9

4.3 SHAP 11

4.4 Pontos de corte e faixas de decisão 11

5. Resultados — Bank Marketing 13

5.1 Comparação dos modelos 13

5.2 Melhor modelo no teste 13

5.3 SHAP 15

5.4 Pontos de corte e faixas de decisão 15

6. Resultados — Breast Cancer Wisconsin 17

6.1 Comparação dos modelos 17

6.2 Melhor modelo no teste 17

6.3 SHAP 19

6.4 Pontos de corte e faixas de decisão 19

7. Comparação entre domínios e conclusões 21

8. Entregáveis e instruções de execução 22

9. Referências 23

1 Bases de dados

As três bases vêm do UCI Machine Learning Repository, têm licença CC BY 4.0 (uso acadêmico e redistribuição permitidos com atribuição) e são entregues como CSV junto do notebook. Cada uma define um problema de classificação binária com a classe positiva explícita.

Domínio	Arquivo CSV	Fonte	Licença	Instâncias	Variável-alvo	Classe positiva (pergunta)
SMS Spam	`SMSSpamCollection.csv`	SMS Spam Collection — T. Almeida, J. Hidalgo (2011), DOI 10.24432/C5CC84	CC BY 4.0	5.572 mensagens (5.169 sem as repetidas)	`target`	`spam` — "a mensagem é spam?"
Bank Marketing	`bank.csv`	Bank Marketing — S. Moro, P. Rita, P. Cortez (2014), DOI 10.24432/C5K306; `bank.csv` é a amostra de 10% da base completa	CC BY 4.0	4.521 clientes	`y`	`yes` — "o cliente vai aderir ao depósito a prazo?"
Breast Cancer	`breast_cancer_wisconsin.csv`	Breast Cancer Wisconsin (Diagnostic) — W. Wolberg, O. Mangasarian, N. Street, W. Street (1993), DOI 10.24432/C5DW2B	CC BY 4.0	569 exames	`diagnostico`	`M` — "o tumor é maligno?"

No SMS Spam, 403 das 5.572 mensagens são cópias idênticas de outra. O programa as remove logo após o carregamento, para que a mesma mensagem não apareça no treino e no teste; restam 5.169. Bank Marketing e Breast Cancer não têm linhas repetidas.

O balanceamento foi verificado pelo próprio programa (seção 2 do notebook), contando as instâncias de cada classe, já sem as repetidas:

Domínio	Classe negativa	Classe positiva	Acurácia de quem sempre prevê a classe majoritária
SMS Spam	4.516 ham (87,37%)	653 spam (12,63%)	87,37%
Bank Marketing	4.000 não aderiram (88,48%)	521 aderiram (11,52%)	88,48%
Breast Cancer	357 benignos (62,74%)	212 malignos (37,26%)	62,74%

No Bank Marketing, a coluna `duration` (duração da última ligação) foi removida. Ela só é conhecida depois que a ligação termina, então usá-la seria vazamento de dados; a documentação original da base recomenda descartá-la num modelo preditivo realista.

2 Programa da Parte 1 — histograma e faixas de decisão

O programa é a função `analisar_pontos_de_corte(y_real, y_prob, t1, t2, largura_intervalo, nome_classe_positiva, nomes_faixas, titulo)`, escrita uma única vez e aplicada às três bases sem alteração. Ela devolve o gráfico e duas tabelas: a composição das faixas e os erros das decisões automáticas.

Item	Como o programa atende
(i) Reutilizável	Recebe apenas rótulos reais (0/1) e probabilidades da classe positiva, então funciona com qualquer base e qualquer modelo que tenha `predict_proba`.
(ii) Entradas e dados finais	Recebe `y_real` e `y_prob`. Os resultados finais (seção 10 do notebook e seções 4 a 6 deste relatório) usam só o conjunto de teste.
(iii) Probabilidade de todas as instâncias	`y_prob` é a probabilidade da classe positiva para todas as instâncias, independentemente do rótulo real. A classe positiva de cada base está definida na seção 1.
(iv) Eixos	Eixo X: probabilidade estimada da classe positiva, de 0% a 100%. Eixo Y: percentual de instâncias em cada intervalo. O azul é calculado sobre o total do conjunto avaliado; o vermelho, sobre o total de positivos reais (item vii).
(v) Intervalos configuráveis	`largura_intervalo` define a largura (10 pontos percentuais neste trabalho). O último intervalo é fechado em 100% e o código confere que cada instância cai em exatamente um intervalo.
(vi) Azul	Distribuição de todas as instâncias do conjunto avaliado, em % do total. As barras azuis somam 100%.
(vii) Vermelho	Distribuição das instâncias com rótulo real positivo, nos mesmos intervalos do azul. As duas barras ficam lado a lado em cada intervalo, com o valor escrito em cima, e a legenda identifica as duas distribuições. **Denominador:** o texto do item pede o mesmo denominador do azul (total de instâncias). Seguimos a correção feita em aula e o exemplo desenhado no enunciado, em que o vermelho é calculado sobre o total de positivos reais e as barras vermelhas também somam 100%. Assim o vermelho mostra onde ficam os positivos. Sobre o total de instâncias, as barras vermelhas somariam só a proporção de positivos (12,63% no spam e 11,52% no bank) e quase sumiriam no gráfico.
(viii) Dois pontos de corte	Negativa automática: p < t1. Análise manual: t1 ≤ p < t2. Positiva automática: p ≥ t2. As faixas aparecem sombreadas no gráfico, e a legenda traz o percentual da população e dos positivos em cada faixa. Esses percentuais são calculados instância a instância, então valem mesmo quando um corte cai no meio de um intervalo. Os cortes são escolhidos na validação e aplicados ao teste sem novos ajustes.

As tabelas de saída trazem, para cada faixa, o percentual da população, a quantidade e a proporção de positivos e negativos, e a parcela do total de positivos que cai na faixa. Trazem também as duas proporções de erro pedidas, cada uma com o denominador escrito:

- Positivos classificados automaticamente como negativos, sobre o total de positivos reais e sobre o total da faixa negativa automática.
- Negativos classificados automaticamente como positivos, sobre o total de negativos reais e sobre o total da faixa positiva automática.

3 Metodologia

O mesmo notebook roda os três domínios; muda apenas a configuração da base. A sequência segue a da aula: classe positiva, balanceamento, separação, representação, busca de hiperparâmetros, SHAP e avaliação, seguida dos pontos de corte. A semente 42 fixa todos os sorteios.

3.1 Balanceamento e escolha da métrica principal

A métrica principal, usada para otimizar e para escolher o melhor modelo, é o **F1 da classe positiva** nos três domínios.

- **SMS Spam (12,63% de spam):** um modelo que nunca aponta spam tem 87,37% de acurácia e é inútil. Os dois erros têm custo: spam que passa incomoda, e mensagem legítima bloqueada é pior. O F1 equilibra precisão e recall do spam.
- **Bank Marketing (11,52% de adesão):** a acurácia de referência é 88,48%. Interessa encontrar os aderentes (recall) sem desperdiçar ligações demais (precisão), exatamente o que o F1 combina.
- **Breast Cancer (37,26% de malignos):** a base é menos desbalanceada, mas os erros têm pesos diferentes. Um falso negativo atrasa o diagnóstico e é o erro grave. O F1 foi mantido para comparar os domínios, e o custo maior do falso negativo entra na escolha dos pontos de corte (seção 3.7).

3.2 Separação dos dados e validação

- Antes da separação, as mensagens repetidas do SMS Spam são removidas (`drop_duplicates` na coluna de texto). Com elas, 151 das 1.393 mensagens de teste tinham cópia idêntica no treino, o que inflava as métricas.
- `train_test_split` com 75% para desenvolvimento e 25% para teste, estratificado pela classe (`stratify=y`), para manter a proporção de positivos nos dois conjuntos.
- O teste fica reservado: só é usado na avaliação final e na aplicação das faixas.
- A validação é uma validação cruzada estratificada de 5 folds (`StratifiedKFold`, com embaralhamento) dentro do conjunto de desenvolvimento. Ela escolhe os hiperparâmetros, escolhe o melhor algoritmo e gera as probabilidades usadas para escolher os pontos de corte.

3.3 Pré-processamento e representação

- **SMS Spam:** TF-IDF da coluna de texto, com unigramas e bigramas, vocabulário de 500 termos e tokens formados só por letras (mesmos parâmetros da aula).
- **Bank Marketing:** One-Hot Encoding das 9 colunas categóricas e padronização (média 0, desvio 1) das 6 numéricas, totalizando 50 atributos.
- **Breast Cancer:** padronização das 30 medidas numéricas dos núcleos celulares.

As transformações ficam dentro de um `Pipeline` junto com o classificador. Assim, na validação cruzada, o TF-IDF, o One-Hot e a padronização são reajustados em cada fold usando apenas os dados de treino daquele fold, e nunca veem o fold de validação nem o teste.

3.4 Algoritmos e otimização de hiperparâmetros

Cada domínio compara três algoritmos de naturezas diferentes. Dois são comuns aos três domínios: Random Forest, um conjunto de árvores (não linear), e Regressão Logística (linear). O terceiro depende do tipo de dado:

- **Naive Bayes Multinomial** no spam: feito para frequências de palavras, não aceita os valores negativos gerados pela padronização das outras bases.
- **Gradient Boosting** no bank: árvores em sequência, fortes em dados tabulares com colunas categóricas e numéricas.
- **SVM com kernel RBF** no breast: adequado a bases pequenas e numéricas; fica lento em bases maiores.

Os hiperparâmetros foram otimizados com `RandomizedSearchCV`: 30 combinações sorteadas por algoritmo (20 no Naive Bayes, cuja grade só tem 20), avaliadas pelo F1 médio nos 5 folds. A grade do Random Forest é a da aula. Em Random Forest, Regressão Logística e SVM, `class_weight="balanced"` entrou como opção para lidar com o desbalanceamento. O melhor modelo de cada domínio é o de maior F1 médio na validação; depois ele é retreinado com todo o conjunto de desenvolvimento.

3.5 Avaliação no teste e construção das curvas

As métricas que dependem de uma decisão (acurácia, precisão, recall, F1 e matriz de confusão) usam **limiar de 0,50** sobre a probabilidade da classe positiva: probabilidade ≥ 0,50 vira positivo. AUC-ROC, AUC-PR e AP usam as probabilidades, sem limiar fixo.

As curvas são construídas variando esse limiar de 1 até 0; em cada valor, as instâncias acima dele são classificadas como positivas e as taxas são recalculadas.

- **Curva ROC:** taxa de falsos positivos, FP/(FP+TN), no eixo X, e taxa de verdadeiros positivos (recall), TP/(TP+FN), no eixo Y. A AUC-ROC é a área sob essa curva e equivale à probabilidade de um positivo sorteado receber pontuação maior que um negativo sorteado. 0,5 é um classificador aleatório; 1,0 é separação perfeita.
- **Curva Precision-Recall:** recall no eixo X e precisão, TP/(TP+FP), no eixo Y. A referência de um classificador aleatório é a proporção de positivos. Em bases desbalanceadas ela é mais exigente que a ROC, porque poucos falsos positivos já derrubam a precisão.

A área sob a curva PR foi calculada de duas formas, reportadas separadamente:

- **AUC-PR (trapezoidal):** integração pela regra do trapézio entre pontos consecutivos da curva (`sklearn.metrics.auc`).
- **Average Precision (AP):** média das precisões em cada limiar, ponderada pelo ganho de recall, sem interpolação (`average_precision_score`):

$$AP = \sum_n (R_n - R_{n-1}) \cdot P_n$$

3.6 Explicação com SHAP

O gráfico beeswarm do melhor modelo usa uma amostra aleatória do **conjunto de teste**, já transformada pelo pré-processamento. Cada ponto é uma instância; a posição é a contribuição da característica para a saída do modelo, e a cor é o valor da característica (vermelho alto, azul baixo). O

explicador e a saída explicada dependem do modelo:

Modelo	Explicador	Saída explicada	Dados
Random Forest	`TreeExplainer`	Probabilidade da classe positiva	200 instâncias do teste
Regressão Logística	`LinearExplainer` (referência: 200 instâncias do treino)	Log-odds (margem) da classe positiva	200 instâncias do teste
SVM	Explicador por permutação (referência: 50 instâncias do treino)	Probabilidade da classe positiva	100 instâncias do teste

Os melhores modelos deste trabalho foram o Random Forest (spam e bank) e o SVM (breast). O explicador linear fica disponível no programa para o caso de a Regressão Logística vencer.

3.7 Escolha dos pontos de corte

Como a validação é cruzada, as probabilidades de validação são **out-of-fold** (`cross_val_predict`): cada instância do desenvolvimento recebe a probabilidade de um modelo que não a viu no treino. Sobre elas foi aplicada a regra:

- **t1** = maior limiar em que no máximo X% dos positivos reais ficam abaixo dele (erro da faixa negativa automática).
- **t2** = menor limiar em que no máximo Y% dos negativos reais ficam acima dele (erro da faixa positiva automática).

Com os erros limitados, as faixas automáticas ficam as maiores possíveis e a análise manual recebe o restante. As tolerâncias X e Y refletem o custo dos erros em cada domínio e são justificadas nas seções 4 a 6. Os cortes são aplicados ao teste sem nenhum ajuste.

4 Resultados — SMS Spam

O Random Forest foi o melhor modelo, com F1 de 0,9322 na validação e 0,8932 no teste. Com os cortes t1 = 0,38 e t2 = 0,50, 83,60% das mensagens de teste são decididas automaticamente, com 8 das 1.130 mensagens legítimas bloqueadas (0,71%).

4.1 Comparação dos modelos

Algoritmo	F1 médio (validação)	Desvio entre folds	Melhores hiperparâmetros
Random Forest	**0,9322**	0,0122	200 árvores, max_depth 10, min_samples_split 10, min_samples_leaf 4, max_features log2, gini, class_weight balanced_subsample
Regressão Logística	0,9276	0,0111	C = 5, solver lbfgs, sem class_weight
Naive Bayes Multinomial	0,8870	0,0251	alpha = 0,3, fit_prior True

Algoritmo (teste, limiar 0,50)	Acurácia	Precisão	Recall	F1	AUC-ROC	AUC-PR (trapezoidal)	AP
Random Forest	0,9745	0,9452	0,8466	0,8932	0,9829	0,9427	0,9428
Regressão Logística	0,9753	0,9517	0,8466	0,8961	0,9855	0,9584	0,9585
Naive Bayes Multinomial	0,9667	0,9412	0,7853	0,8562	0,9856	0,9446	0,9447

Matrizes de confusão no teste (TP / FP / FN / TN, em 163 spams e 1.130 hams): Random Forest 138 / 8 / 25 / 1.122; Regressão Logística 138 / 7 / 25 / 1.123; Naive Bayes 128 / 8 / 35 / 1.122.

- **Random Forest:** o escolhido pela validação. No teste, detecta 138 dos 163 spams (recall 0,847) e marca 8 mensagens legítimas como spam (precisão 0,945).
- **Regressão Logística:** praticamente igual no limiar 0,50, com uma mensagem legítima a menos marcada como spam, e com áreas maiores (AP 0,959 contra 0,943).
- **Naive Bayes:** o menor recall (0,785): perde cerca de 1 em cada 5 spams.

A diferença entre Random Forest e Regressão Logística na validação (0,0046) é menor que o desvio entre folds, então os dois estão empatados. A escolha seguiu a regra do trabalho: o maior F1 na validação, sem consultar o teste. No teste, o F1 ficou 0,039 abaixo da validação; com 163 spams no teste, cada spam vale 0,6 ponto de recall. A acurácia de 97,4% supera a referência de 87,4% (sempre "ham"), mas é o F1 que mostra a qualidade na classe spam.

Efeito da remoção das repetidas. Numa execução anterior, ainda com as 403 cópias na base, o melhor modelo chegava a F1 de 0,950 no teste; sem elas, 0,893. Parte da diferença vem do vazamento removido e parte vem da nova divisão treino/teste.

4.2 Melhor modelo no teste

Matriz de confusão do Random Forest (limiar 0,50): **138 spams detectados, 25 spams que passaram, 8 mensagens legítimas marcadas como spam e 1.122 legítimas corretas**, em 1.293 mensagens de teste.

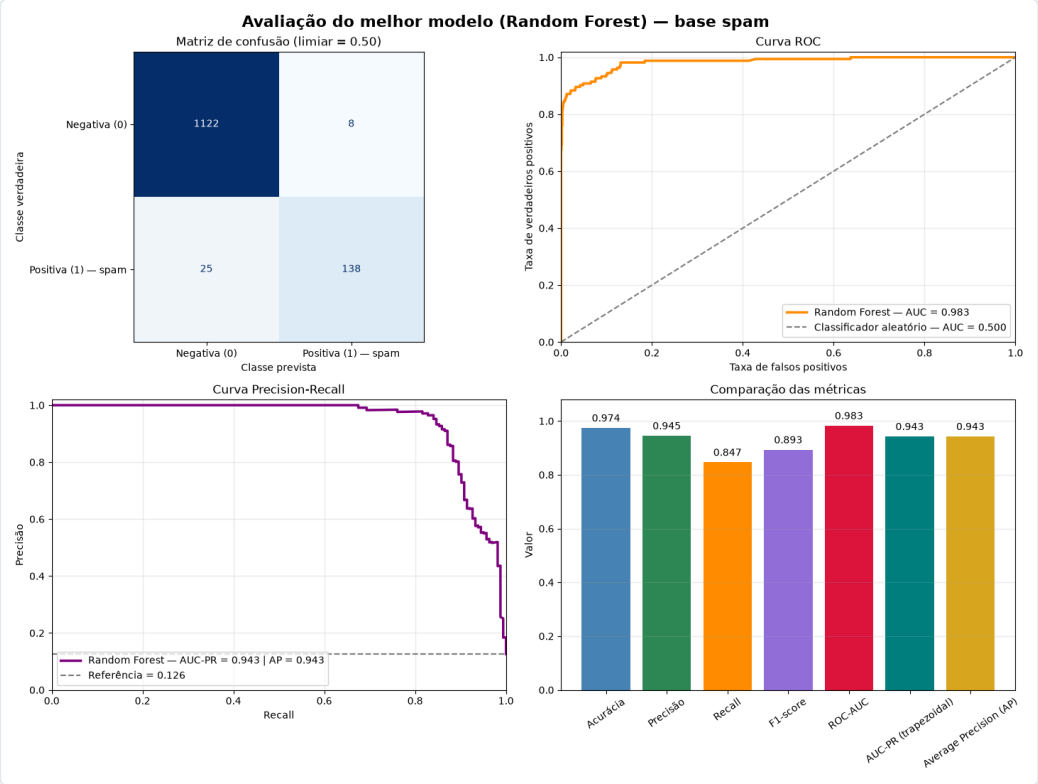


Figura 1 — Avaliação do melhor modelo no SMS Spam: matriz de confusão, curva ROC, curva Precision-Recall e métricas.

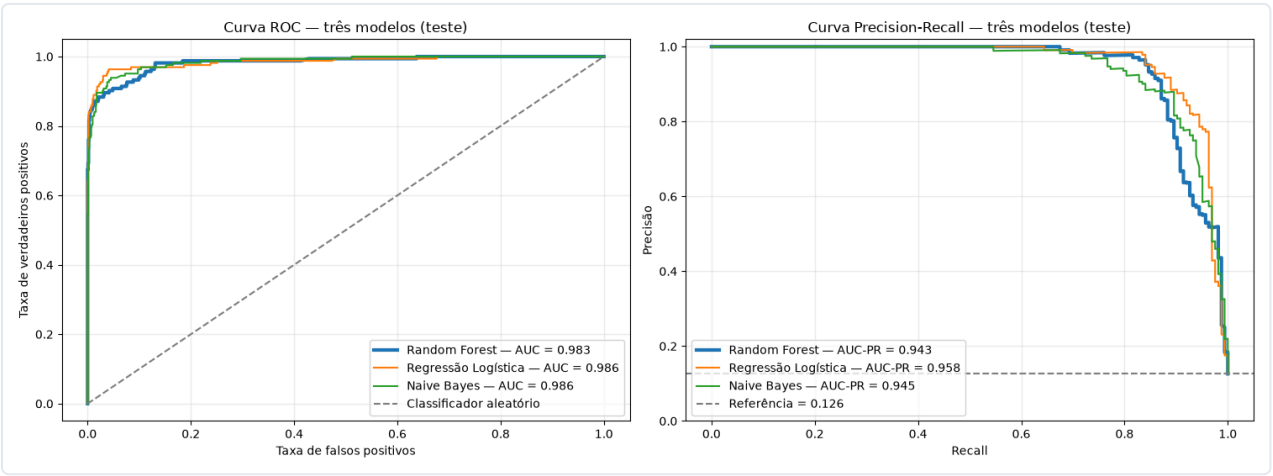


Figura 2 — Curvas ROC e Precision-Recall dos três modelos no teste do SMS Spam.

4.3 SHAP

Saída explicada: **probabilidade de spam** prevista pelo Random Forest. Dados: 200 mensagens sorteadas do conjunto de teste.

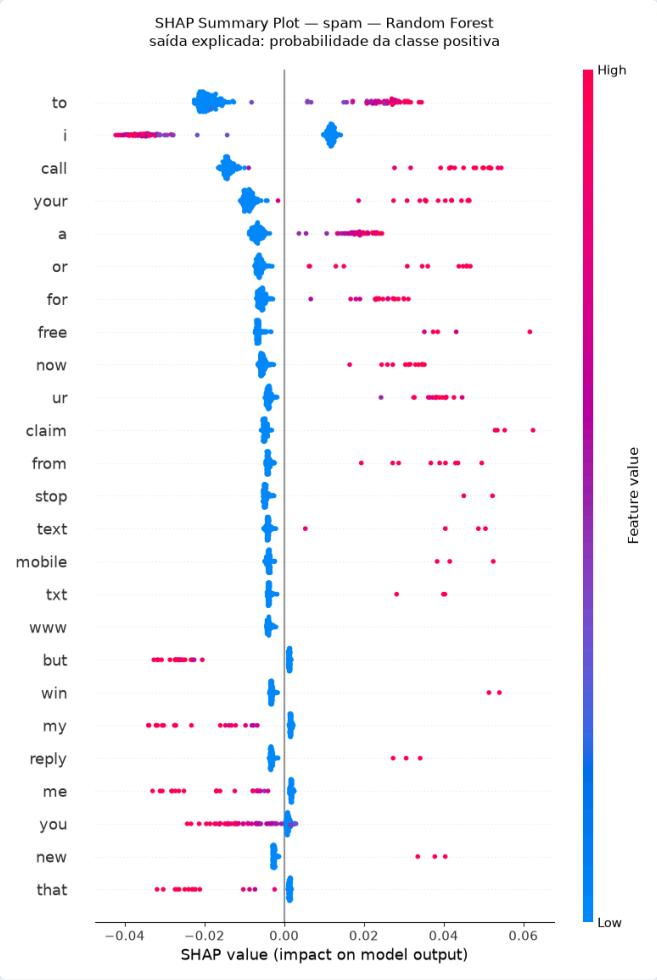


Figura 3 — SHAP beeswarm do Random Forest no SMS Spam.

- **Aumentam a chance de spam** quando presentes (pontos vermelhos à direita): `call`, `your`, `or`, `for`, `free`, `now`, `ur`, `claim`, `from`, `stop`, `text`, `mobile`, `txt`, `win` e `reply`. Presentes, somam até 6 pontos percentuais à probabilidade; `claim` e `free` são as que mais pesam. É o vocabulário de promoções e serviços por SMS.
- **Diminuem a chance de spam** quando presentes: `i`, `but`, `my`, `me`, `you` e `that`, típicos de conversa pessoal. O `i` tira de 3 a 4 pontos.
- Palavras muito frequentes, como `to` e `a`, também aparecem no topo e, quando presentes, aumentam a chance de spam em até 3 pontos.
- **A ausência também conta** (pontos azuis afastados do zero): não ter `to` tira cerca de 2 pontos, não ter `call` tira 1,5, e não ter `i` soma 1. Para o modelo, uma mensagem sem o vocabulário de promoção já é um indício de mensagem legítima.

Em várias linhas os pontos formam nuvens, com roxos perto do zero (`to`, `a`, `you`): numa floresta, o efeito de uma palavra depende das outras palavras da mensagem.

4.4 Pontos de corte e faixas de decisão

Tolerâncias: **até 3% dos spams** na faixa negativa automática e **até 0,5% das mensagens legítimas** na faixa positiva automática. Bloquear uma mensagem legítima é bem pior do que deixar passar um spam, por isso Y é muito menor que X.

Na validação (3.876 mensagens out-of-fold), a regra deu **t1 = 0,38 e t2 = 0,50**, com 14 de 490 spams (2,86%) abaixo de t1 e 14 de 3.386 legítimas (0,41%) acima de t2.

Resultado no teste, com os cortes sem ajuste:

Faixa	Mensagens	% da população	Spam	Ham	% de spam na faixa	% de ham na faixa	% do total de spam
Negativo automático (entregar), p < 0,38	935	72,31%	3	932	0,32%	99,68%	1,84%
Análise manual, 0,38 ≤ p < 0,50	212	16,40%	22	190	10,38%	89,62%	13,50%
Positivo automático (spam), p ≥ 0,50	146	11,29%	138	8	94,52%	5,48%	84,66%

Erro das decisões automáticas	Numerador	Denominador	Proporção
Spam classificado automaticamente como negativo	3	163 (total de spams reais)	1,84%
Spam classificado automaticamente como negativo	3	935 (total da faixa negativa automática)	0,32%
Ham classificado automaticamente como spam	8	1.130 (total de hams reais)	0,71%
Ham classificado automaticamente como spam	8	146 (total da faixa positiva automática)	5,48%

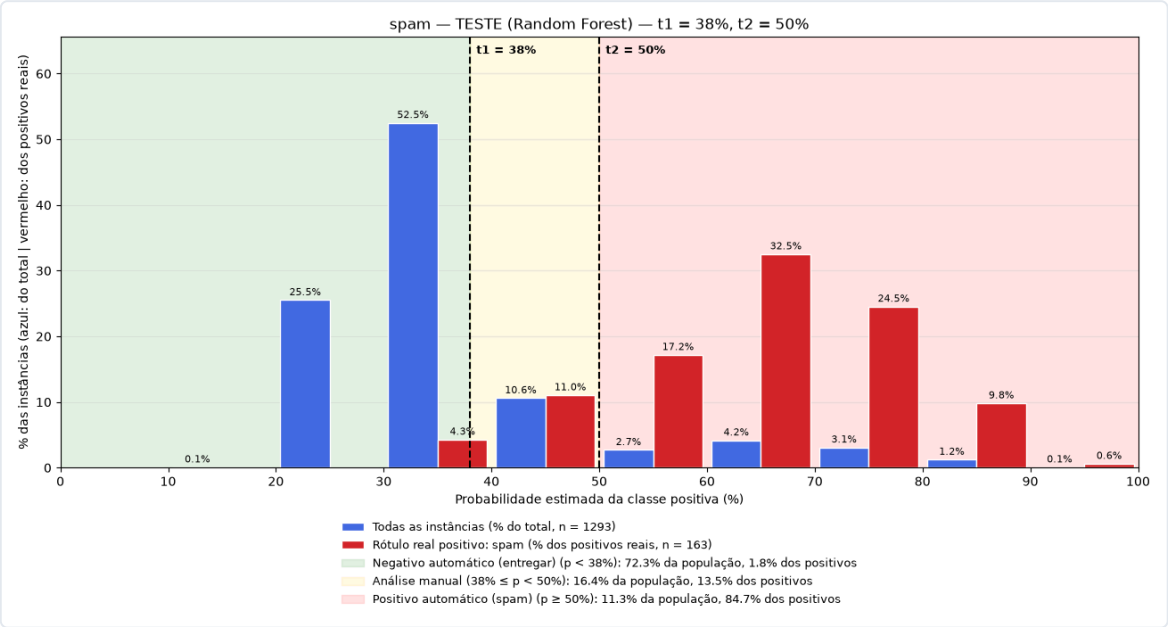


Figura 4 — Histograma de probabilidades do teste no SMS Spam com t1 e t2.

No gráfico, 78,0% das mensagens ficam entre 20% e 40% de probabilidade, e 84,7% dos spams ficam acima de 50%. Esse Random Forest não dá probabilidades extremas: quase nenhuma mensagem recebe menos de 20% ou mais de 90%. Por isso os dois cortes ficaram próximos.

> **Política:** 83,60% das mensagens são decididas sem intervenção. A análise manual recebe 16,40% do volume, uma faixa de fato ambígua (10,38% de spam). No teste, 3 dos 163 spams (1,84%) caíram na faixa de entrega automática, dentro da tolerância de 3%. Já as mensagens legítimas bloqueadas foram 8 de 1.130 (0,71%), acima da tolerância de 0,5%. É o erro grave do domínio; em uso real, valeria uma tolerância menor para t2, ao custo de mais análise manual. Os cortes não foram ajustados depois de ver o teste.

5 Resultados — Bank Marketing

> O Random Forest foi o melhor modelo, com F1 de 0,4048 na validação e 0,3455 no teste. Sem a duração da ligação, o sinal disponível antes do contato é fraco (AUC-ROC 0,74), e a triagem automática cobre 14% dos clientes.

5.1 Comparação dos modelos

Algoritmo	F1 médio (validação)	Desvio entre folds	Melhores hiperparâmetros
Random Forest	**0,4048**	0,0415	200 árvores, max_depth 10, min_samples_split 10, min_samples_leaf 4, max_features log2, gini, class_weight balanced_subsample
Regressão Logística	0,3324	0,0331	C = 1, solver liblinear, class_weight balanced
Gradient Boosting	0,3274	0,0643	100 árvores, learning_rate 0,2, max_depth 5, subsample 0,7, min_samples_leaf 5

Algoritmo (teste, limiar 0,50)	Acurácia	Precisão	Recall	F1	AUC-ROC	AUC-PR (trapezoidal)	AP
Random Forest	0,8258	0,3041	0,4000	0,3455	0,7421	0,3203	0,3245
Regressão Logística	0,7065	0,2131	0,5769	0,3112	0,7254	0,2863	0,2914
Gradient Boosting	0,8789	0,4407	0,2000	0,2751	0,6928	0,2829	0,2871

Matrizes de confusão no teste (TP / FP / FN / TN, em 130 aderentes e 1.001 não-aderentes): Random Forest 52 / 119 / 78 / 882; Regressão Logística 75 / 277 / 55 / 724; Gradient Boosting 26 / 33 / 104 / 968.

- **Random Forest:** o melhor equilíbrio no limiar 0,50: encontra 40,0% dos aderentes e acerta 3 em cada 10 contatos que indica.
- **Regressão Logística:** com `class_weight` balanced, aponta muitos clientes como aderentes; tem o maior recall (0,577) e a menor precisão (0,213).
- **Gradient Boosting:** o oposto: é conservador no limiar 0,50 (recall 0,200, precisão 0,441). Tem também as menores áreas (AUC-ROC 0,693) e foi o mais instável na validação (desvio de 0,064).

As três AUC-ROC ficam entre 0,69 e 0,74 e as AUC-PR em torno de 0,3, de 2,5 a 2,8 vezes a referência aleatória (0,115). O limite é da base, não do algoritmo: sem `duration`, sobram o perfil do cliente e o histórico de campanhas. A acurácia confirma por que ela não serve aqui: o Gradient Boosting tem 87,9%, menos que o modelo que nunca prevê adesão (88,5%), e ainda assim parece um número alto.

5.2 Melhor modelo no teste

Matriz de confusão do Random Forest (limiar 0,50): **52 aderentes encontrados, 78 aderentes perdidos, 119 contatos sem adesão e 882 não-aderentes corretos**, em 1.131 clientes de teste.

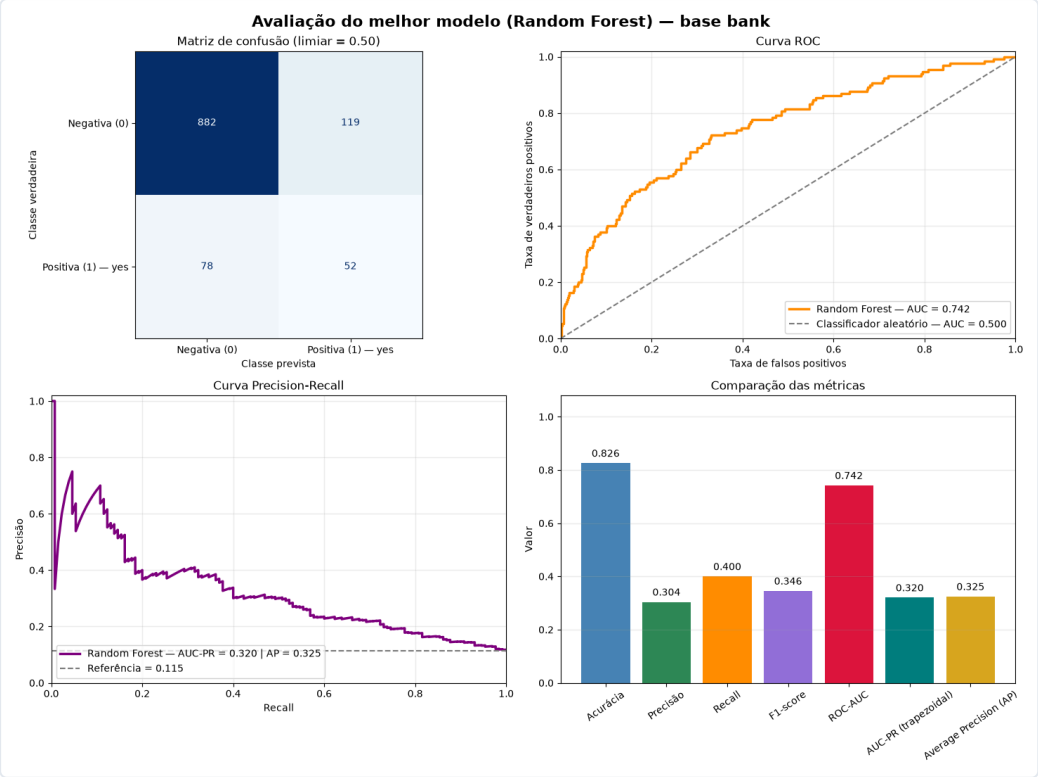


Figura 5 — Avaliação do melhor modelo no Bank Marketing: matriz de confusão, curva ROC, curva Precision-Recall e métricas.

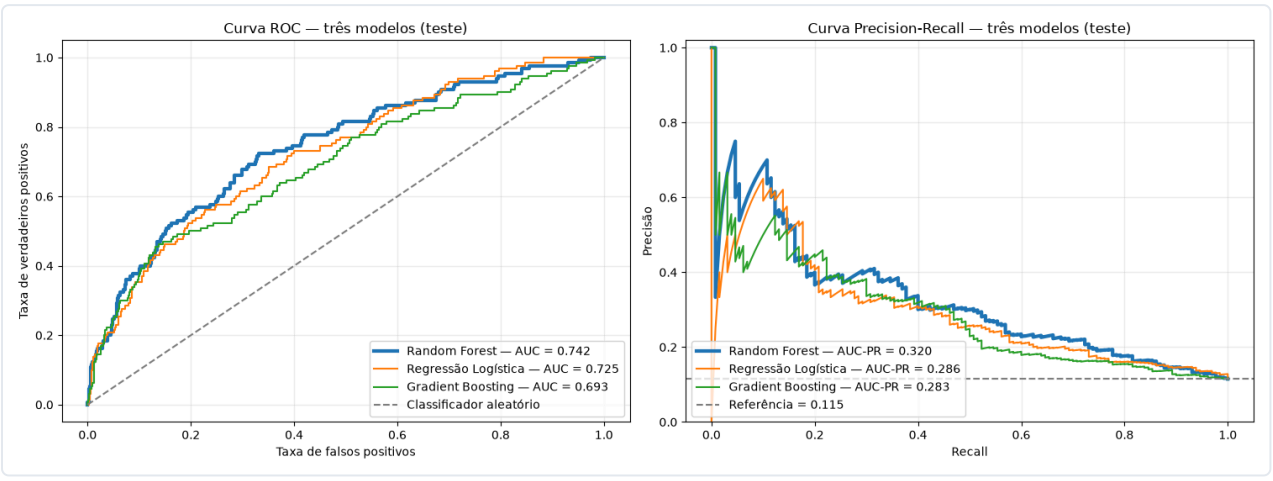


Figura 6 — Curvas ROC e Precision-Recall dos três modelos no teste do Bank Marketing.

5.3 SHAP

Saída explicada: **probabilidade de adesão** prevista pelo Random Forest. Dados: 200 clientes sorteados do conjunto de teste.

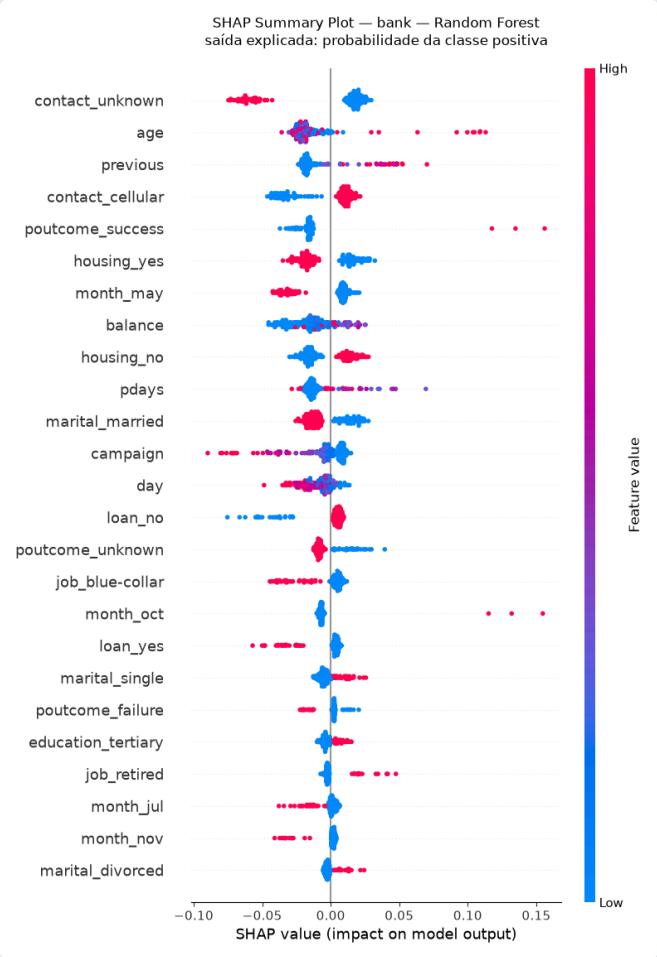


Figura 7 — SHAP beeswarm do Random Forest no Bank Marketing.

- **Forma de contato:** `contact_unknown` = 1 (contato sem registro do meio) diminui a probabilidade; `contact_cellular` = 1 aumenta. É a característica mais relevante do modelo.
- **Histórico com o banco:** `poutcome_success` = 1 (adesão numa campanha anterior) é o maior aumento individual, de até +0,15, embora raro. `previous` alto (mais contatos em campanhas anteriores) também aumenta.
- **Idade:** a maioria das idades tem efeito pequeno e negativo, mas idades altas aumentam bastante a chance, junto com `job_retired`.
- **Compromissos financeiros:** `housing_yes` (financiamento imobiliário) e `loan_yes` (empréstimo) diminuem; `housing_no` e `loan_no` aumentam.
- **Campanha e época:** `campaign` alto (muitas ligações nesta campanha) diminui; `month_may` diminui, e `month_oct` aumenta em poucos casos.

5.4 Pontos de corte e faixas de decisão

Neste domínio, as faixas viram ações de marketing: **não contatar**, **contato padrão** e **contato prioritário**. Tolerâncias: **até 2% dos aderentes** no grupo "não contatar" (perder um aderente custa uma venda) e **até 5% dos não-aderentes** no grupo prioritário (uma ligação prioritária sem retorno custa pouco).

Na validação (3.390 clientes out-of-fold), a regra deu **t1 = 0,16 e t2 = 0,56**, com 3 de 391 aderentes (0,77%) abaixo de t1 e 144 de 2.999 não-aderentes (4,80%) acima de t2.

Resultado no teste, com os cortes sem ajuste:

Faixa	Clientes	% da população	Aderiram	Não aderiram	% de aderentes na faixa	% de não-aderentes na faixa	% do total de aderentes
Não contatar, p < 0,16	49	4,33%	1	48	2,04%	97,96%	0,77%
Contato padrão, 0,16 ≤ p < 0,56	973	86,03%	87	886	8,94%	91,06%	66,92%
Contato prioritário, p ≥ 0,56	109	9,64%	42	67	38,53%	61,47%	32,31%

Erro das decisões automáticas	Numerador	Denominador	Proporção
Aderente classificado automaticamente como negativo	1	130 (total de aderentes reais)	0,77%
Aderente classificado automaticamente como negativo	1	49 (total da faixa "não contatar")	2,04%
Não-aderente classificado automaticamente como positivo	67	1.001 (total de não-aderentes reais)	6,69%
Não-aderente classificado automaticamente como positivo	67	109 (total da faixa prioritária)	61,47%

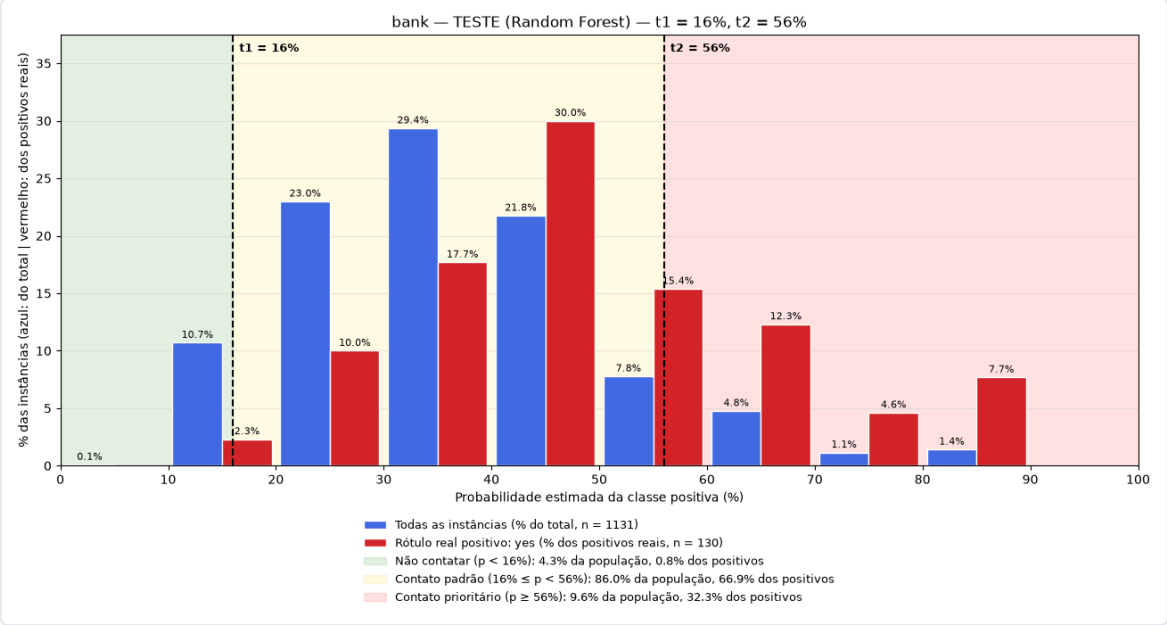


Figura 8 — Histograma de probabilidades do teste no Bank Marketing com t1 e t2.

No gráfico, o vermelho fica à direita do azul, mas as duas distribuições se sobrepõem em quase todo o eixo: entre 20% e 60% de probabilidade estão cerca de 82% dos clientes e 73,1% dos aderentes.

> **Política:** o grupo prioritário tem 38,53% de adesão, 3,4 vezes a taxa geral de 11,5%, e concentra 42 dos 130 aderentes (32,3%) em menos de 10% dos clientes. O grupo "não contatar" libera 4,33% das ligações perdendo só 1 aderente (0,77%). O contato padrão fica com 86% da base, com adesão de 8,94%, próxima da geral: é onde o modelo pouco acrescenta, e a campanha segue como antes. No teste, 6,69% dos não-aderentes caíram no grupo prioritário, acima dos 5% da validação, mas é o erro de menor custo. O limite desta política é o sinal fraco da base: não há corte que automatize muito mais sem perder aderentes.

6 Resultados — Breast Cancer Wisconsin

> O SVM com kernel RBF foi o melhor modelo, com F1 de 0,9747 na validação e 0,9608 no teste, sem nenhum falso positivo. Com os cortes t1 = 0,06 e t2 = 0,68, 88,12% dos exames de teste são decididos automaticamente, com 1 tumor maligno na faixa "provável benigno".

6.1 Comparação dos modelos

Algoritmo	F1 médio (validação)	Desvio entre folds	Melhores hiperparâmetros
SVM (RBF)	**0,9747**	0,0126	C = 5, gamma auto, sem class_weight
Regressão Logística	0,9675	0,0234	C = 0,5, solver liblinear, sem class_weight
Random Forest	0,9518	0,0207	300 árvores, max_depth 30, min_samples_split 2, min_samples_leaf 2, max_features 0,3, entropy, class_weight balanced_subsample

Algoritmo (teste, limiar 0,50)	Acurácia	Precisão	Recall	F1	AUC-ROC	AUC-PR (trapezoidal)	AP
SVM (RBF)	0,9720	1,0000	0,9245	0,9608	0,9948	0,9925	0,9926
Regressão Logística	0,9790	1,0000	0,9434	0,9709	0,9973	0,9960	0,9960
Random Forest	0,9720	1,0000	0,9245	0,9608	0,9977	0,9965	0,9966

Matrizes de confusão no teste (TP / FP / FN / TN, em 53 malignos e 90 benignos): SVM 49 / 0 / 4 / 90; Regressão Logística 50 / 0 / 3 / 90; Random Forest 49 / 0 / 4 / 90.

- Os três modelos têm precisão de 1,000 no teste: nenhum tumor benigno foi apontado como maligno.
- A diferença está no recall: a Regressão Logística deixa passar 3 dos 53 malignos; SVM e Random Forest, 4.
- As AUC ficam acima de 0,99: as 30 medidas dos núcleos celulares separam quase perfeitamente as classes.

No teste, a Regressão Logística foi um pouco melhor que o SVM (um maligno a mais detectado), mas o melhor modelo é escolhido pela validação, e o teste só confirma o desempenho. Com 53 malignos no teste, um caso muda o recall em quase 2 pontos, então os três modelos são equivalentes nesta base.

6.2 Melhor modelo no teste

Matriz de confusão do SVM (limiar 0,50): **49 malignos detectados, 4 malignos não detectados, nenhum benigno classificado como maligno e 90 benignos corretos**, em 143 exames de teste.

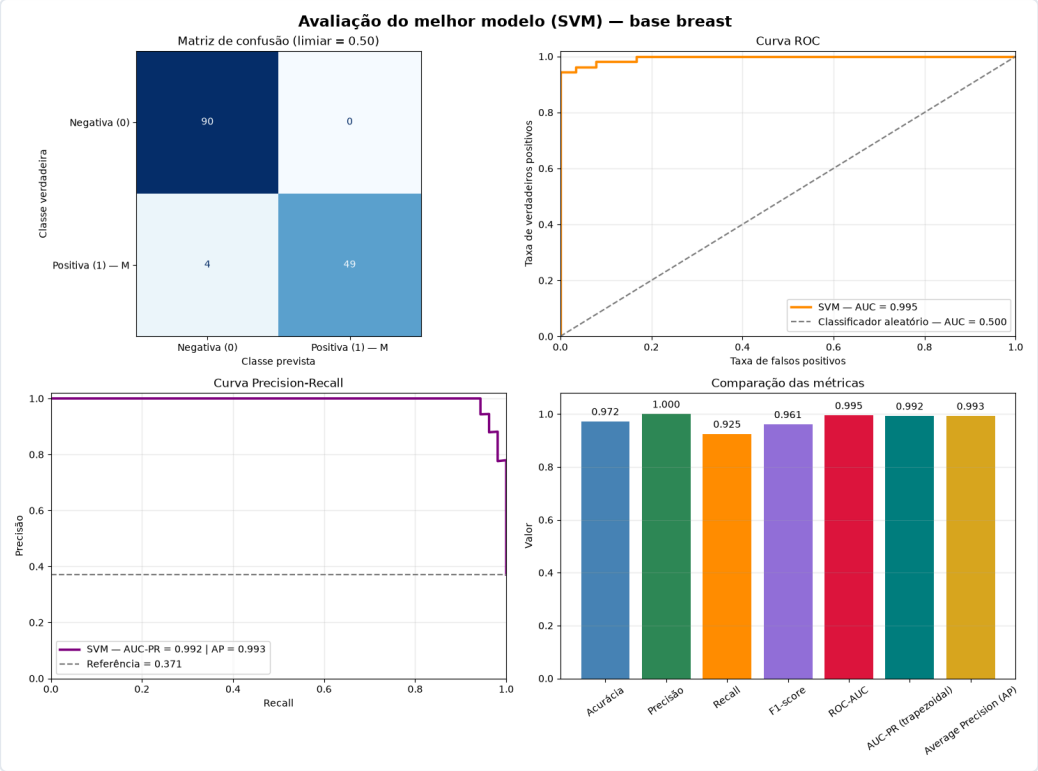


Figura 9 — Avaliação do melhor modelo no Breast Cancer: matriz de confusão, curva ROC, curva Precision-Recall e métricas.

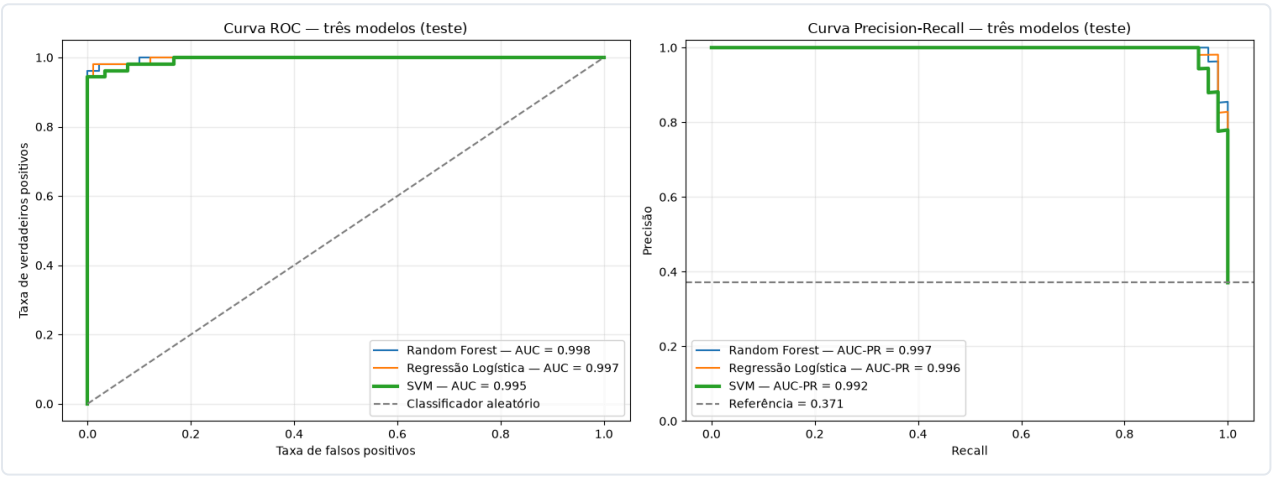


Figura 10 — Curvas ROC e Precision-Recall dos três modelos no teste do Breast Cancer.

6.3 SHAP

Saída explicada: **probabilidade de malignidade** prevista pelo SVM. Dados: 100 exames sorteados do conjunto de teste, com 50 exames do treino como referência do explicador por permutação.

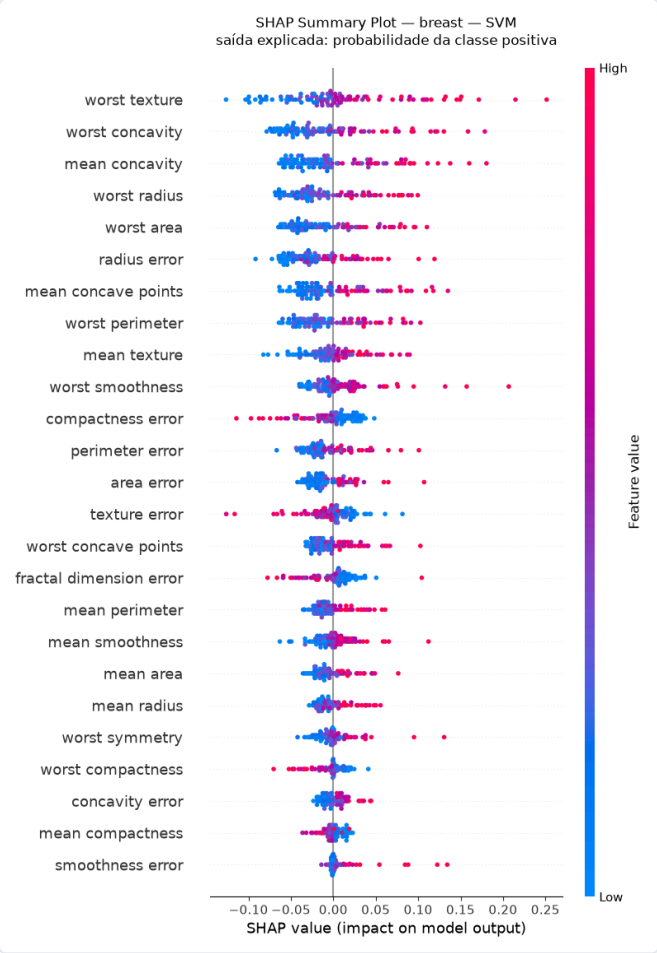


Figura 11 — SHAP beeswarm do SVM no Breast Cancer.

- **Aumentam a probabilidade de malignidade** quando altas: `worst texture`, `worst concavity`, `mean concavity`, `worst radius`, `worst area`, `radius error`, `mean concave points` e `worst perimeter`. São medidas de tamanho, irregularidade da textura e concavidade do contorno dos núcleos, sobretudo nos piores valores de cada exame (`worst`).
- **Diminuem quando altas:** `compactness error` e `texture error`, medidas de variação dentro do exame.
- Valores baixos (azul) das medidas de tamanho e concavidade puxam para benigno, o que é coerente com núcleos menores e de contorno mais regular.

6.4 Pontos de corte e faixas de decisão

As faixas representam um fluxo clínico: **provável benigno**, **avaliação especializada** e **forte indicação maligna**. Tolerâncias: **até 1% dos malignos** em "provável benigno", porque um maligno sem investigação é o erro grave, e **até 1% dos benignos** em "forte indicação maligna", para ninguém seguir para tratamento por engano.

Na validação (426 exames out-of-fold), a regra deu **t1 = 0,06 e t2 = 0,68**, com 1 de 159 malignos (0,63%) abaixo de t1 e 2 de 267 benignos (0,75%) acima de t2.

Resultado no teste, com os cortes sem ajuste:

Faixa	Exames	% da população	Malignos	Benignos	% de malignos na faixa	% de benignos na faixa	% do total de malignos
Provável benigno, p < 0,06	77	53,85%	1	76	1,30%	98,70%	1,89%
Avaliação especializada, 0,06 ≤ p < 0,68	17	11,89%	3	14	17,65%	82,35%	5,66%
Forte indicação maligna, p ≥ 0,68	49	34,27%	49	0	100,00%	0,00%	92,45%

Erro das decisões automáticas	Numerador	Denominador	Proporção
Maligno classificado automaticamente como negativo	1	53 (total de malignos reais)	1,89%
Maligno classificado automaticamente como negativo	1	77 (total da faixa "provável benigno")	1,30%
Benigno classificado automaticamente como positivo	0	90 (total de benignos reais)	0,00%
Benigno classificado automaticamente como positivo	0	49 (total da faixa "forte indicação maligna")	0,00%

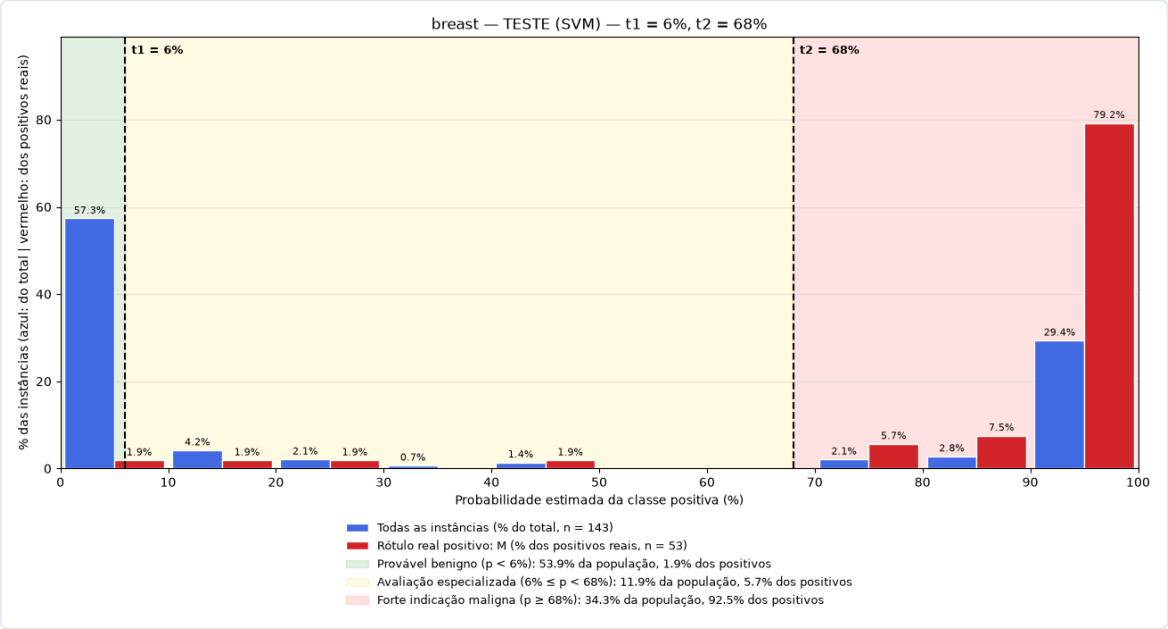


Figura 12 — Histograma de probabilidades do teste no Breast Cancer com t1 e t2.

No gráfico, 57,3% dos exames estão no intervalo de 0 a 10%, e 79,2% dos malignos estão no de 90 a 100%. Entre 10% e 70% ficam só 3 dos 53 malignos (5,7%).

> **Política:** 88,12% dos exames recebem uma indicação automática, sem nenhum benigno na faixa de forte indicação maligna. A avaliação especializada recebe 11,89% dos exames, justamente os ambíguos (17,65% de malignos). O risco residual é 1 maligno em 53 (1,89%) na faixa "provável benigno". Em uso real, a triagem não substituiria o acompanhamento médico, e a equipe clínica decidiria se esse risco é aceitável ou se t1 deve ser ainda menor, com mais exames na avaliação especializada.

7 Comparação entre domínios e conclusões

O quanto as classes se separam decidiu o resultado mais do que o algoritmo. Onde a separação é alta (spam e breast), a triagem automatiza de 84% a 88% dos casos com erros baixos; no bank, o sinal fraco limita tanto o F1 quanto a cobertura.

Domínio	Positivos	Melhor modelo	F1 (teste)	AUC-ROC	AP	t1 / t2	Cobertura automática	Positivos na faixa negativa	Negativos na faixa positiva
SMS Spam	12,63%	Random Forest	0,893	0,983	0,943	0,38 / 0,50	83,60%	1,84% (3/163)	0,71% (8/1.130)
Bank Marketing	11,52%	Random Forest	0,346	0,742	0,325	0,16 / 0,56	13,97%	0,77% (1/130)	6,69% (67/1.001)
Breast Cancer	37,26%	SVM (RBF)	0,961	0,995	0,993	0,06 / 0,68	88,12%	1,89% (1/53)	0,00% (0/90)

- **Acurácia engana em bases desbalanceadas.** No bank, um modelo com 87,9% de acurácia encontrou só 20% dos aderentes. O F1, a AUC-PR e a AP foram as métricas que distinguiram os modelos.
- **Não há algoritmo vencedor em todos os domínios.** O Random Forest venceu no texto e no tabular misto, e o SVM na base numérica pequena. No spam e no breast, o segundo colocado ficou a menos de um desvio entre folds do primeiro; no bank, o Random Forest venceu com folga.
- **Escolher pela validação evita viés de teste.** No spam e no breast, outro modelo foi um pouco melhor no teste, mas trocar o modelo depois de ver o teste tornaria a avaliação final otimista.
- **O pré-processamento dentro do Pipeline** garantiu que TF-IDF, One-Hot e padronização nunca vissem o fold de validação nem o teste.
- **Mensagens repetidas inflavam o spam.** Numa execução anterior, com as 403 cópias, o F1 no teste era 0,950; sem elas, 0,893. Conferir repetições antes da separação faz parte de evitar vazamento.
- **Os pontos de corte transformam probabilidade em política.** As tolerâncias de cada domínio levaram a faixas diferentes: proteger mensagens legítimas no spam, concentrar aderentes no bank e não deixar malignos sem investigação no breast.

> **Limitações.** Os resultados vêm de uma única divisão treino/teste; em bases pequenas, como o teste do breast (53 malignos), um caso muda as taxas em quase 2 pontos. As taxas de erro das faixas no teste ficaram próximas, mas nem sempre abaixo, das tolerâncias da validação (spam e bank). O bank usa a amostra de 10% da base (4.521 de 45.211 clientes); os números podem mudar na base completa. No spam, só foram removidas as mensagens com texto idêntico; as que diferem apenas por números ou pontuação continuam na base. Os números também dependem da versão das bibliotecas: no spam, Random Forest e Regressão Logística ficam empatados na validação, e outra versão do scikit-learn pode inverter o vencedor.

8 Entregáveis e instruções de execução

Integrantes da equipe:

Integrante	RGM
Ana Julia Bernardino Klenk	43455301
André Felipe Lima de Almeida	42970253
João Pedro Galdino e Silva	42661315
Thiago Kauan Cardozo da Silva	43725694

Arquivos entregues:

Arquivo	Conteúdo
`A2_Data-science_versao_certa.ipynb`	Código-fonte: um único notebook com o programa da Parte 1 e a modelagem da Parte 2. Roda qualquer uma das três bases; muda só `BASE_ESCOLHIDA`. O arquivo guarda as saídas da última base executada
`SMSSpamCollection.csv`	Base SMS Spam (separador: tabulação)
`bank.csv`	Base Bank Marketing (separador: ponto e vírgula)
`breast_cancer_wisconsin.csv`	Base Breast Cancer Wisconsin (separador: vírgula)
Este relatório	Metodologia, resultados, gráficos e conclusões

Execução no Google Colab:

1. Em colab.research.google.com, abrir **Arquivo → Fazer upload de notebook** e escolher o notebook.
2. Arrastar os três CSVs para o painel **Arquivos** (ícone de pasta, à esquerda).
3. Na célula de configuração, escolher a base em `BASE_ESCOLHIDA` (`"spam"`, `"bank"` ou `"breast"`) e manter `EXECUCAO_RAPIDA = False`.
4. Usar **Ambiente de execução → Executar tudo**. No Colab gratuito, a execução leva cerca de 10 minutos no spam, 4 no bank e 2 no breast.
5. Para as outras duas bases, trocar `BASE_ESCOLHIDA` e executar tudo de novo. O notebook mostra só as saídas da última execução; os resultados das três bases estão nas seções 4 a 6 deste relatório.

Execução local: Python 3.11 ou mais recente, com `pip install pandas numpy scikit-learn matplotlib shap jinja2 ipykernel`, e os três CSVs na mesma pasta do notebook. Os resultados deste relatório vêm da execução do notebook nas três bases com Python 3.14; com outras versões das bibliotecas, os números podem mudar um pouco.

`EXECUCAO_RAPIDA = True` reduz a busca de hiperparâmetros para demonstrações (cerca de 1 minuto por base), mas altera os resultados; os números deste relatório são do modo normal.

9 Referências

- ALMEIDA, T.; HIDALGO, J. SMS Spam Collection. UCI Machine Learning Repository, 2011. DOI: 10.24432/C5CC84. Licença CC BY 4.0.
- MORO, S.; RITA, P.; CORTEZ, P. Bank Marketing. UCI Machine Learning Repository, 2014. DOI: 10.24432/C5K306. Licença CC BY 4.0.
- WOLBERG, W.; MANGASARIAN, O.; STREET, N.; STREET, W. Breast Cancer Wisconsin (Diagnostic). UCI Machine Learning Repository, 1993. DOI: 10.24432/C5DW2B. Licença CC BY 4.0.
- Bibliotecas: scikit-learn (modelos, pipelines, validação e métricas), shap (explicações), pandas, numpy e matplotlib.