

Trabalho A2 — Classificação binária em três domínios e análise de pontos de corte

30/09/2026 · Andre

Três bases do UCI (SMS Spam, Bank Marketing e Breast Cancer Wisconsin) foram modeladas com o mesmo notebook. Os melhores modelos, escolhidos pelo F1 na validação cruzada, atingiram F1 de 0,950, 0,351 e 0,961 no teste. Com dois pontos de corte escolhidos na validação, 88% das mensagens e dos exames são decididos automaticamente com erro abaixo de 4%. No bank, o sinal fraco limita a triagem automática a 16% dos clientes.

1. Bases de dados

As três bases vêm do UCI Machine Learning Repository, têm licença CC BY 4.0 (uso acadêmico e redistribuição permitidos com atribuição) e são entregues como CSV junto do notebook. Cada uma define um problema de classificação binária com a classe positiva explícita.

Domínio	Arquivo CSV	Fonte	Licença	Instâncias	Variável-alvo	Classe positiva (pergunta)
SMS Spam	SMSSpamCollection.csv	SMS Spam Collection — T. Almeida, J. Hidalgo (2011), DOI 10.24432/C5CC84	CC BY 4.0	5.572 mensagens	target	spam — "a mensagem é spam?"
Bank Marketing	bank.csv	Bank Marketing — S. Moro, P. Rita, P. Cortez (2014), DOI 10.24432/C5K306; bank.csv é a amostra de 10% da base completa	CC BY 4.0	4.521 clientes	y	yes — "o cliente vai aderir ao depósito a prazo?"
Breast Cancer	breast_cancer_wisconsin.csv	Breast Cancer Wisconsin (Diagnostic) — W. Wolberg, O. Mangasarian, N. Street, W. Street (1993), DOI 10.24432/C5DW2B	CC BY 4.0	569 exames	diagnostic	M — "o tumor é maligno?"

O balanceamento foi verificado pelo próprio programa (seção 2 do notebook), contando as instâncias de cada classe:

Domínio	Classe negativa	Classe positiva	Acurácia de quem sempre prevê a classe majoritária
SMS Spam	4.825 ham (86,59%)	747 spam (13,41%)	86,59%
Bank Marketing	4.000 não aderiram (88,48%)	521 aderiram (11,52%)	88,48%
Breast Cancer	357 benignos (62,74%)	212 malignos (37,26%)	62,74%

No Bank Marketing, a coluna `duration` (duração da última ligação) foi removida. Ela só é conhecida depois que a ligação termina, então usá-la seria vazamento de dados; a documentação original da base recomenda descartá-la num modelo preditivo realista.

2. Programa da Parte 1 — histograma e faixas de decisão

O programa é a função `analisar_pontos_de_corte(y_real, y_prob, t1, t2, largura_intervalo, nome_classe_positiva, nomes_faixas, titulo)`, escrita uma única vez e aplicada às três bases sem alteração. Ela devolve o gráfico e duas tabelas: a composição das faixas e os erros das decisões automáticas.

Item	Como o programa atende
(i) Reutilizável	Recebe apenas rótulos reais (0/1) e probabilidades da classe positiva, então funciona com qualquer base e qualquer modelo que tenha <code>predict_proba</code> .
(ii) Entradas e dados finais	Recebe <code>y_real</code> e <code>y_prob</code> . Os resultados finais (seção 10 do notebook e seções 4 a 6 deste relatório) usam só o conjunto de teste.
(iii) Probabilidade de todas as instâncias	<code>y_prob</code> é a probabilidade da classe positiva para todas as instâncias, independentemente do rótulo real. A classe positiva de cada base está definida na seção 1.
(iv) Eixos	Eixo X: probabilidade estimada da classe positiva, de 0% a 100%. Eixo Y: percentual de instâncias de cada intervalo sobre o total do conjunto avaliado.
(v) Intervalos configuráveis	<code>largura_intervalo</code> define a largura (10 pontos percentuais neste trabalho). O último intervalo é fechado em 100% e o código confere que cada instância cai exatamente em um intervalo.
(vi) Azul	Distribuição de todas as instâncias do conjunto avaliado.
(vii) Vermelho	Distribuição das instâncias com rótulo real positivo, com os mesmos intervalos e o mesmo denominador do azul. O vermelho é desenhado sobre o azul por ser um subconjunto dele; a legenda identifica as duas distribuições.
(viii) Dois pontos de corte	Negativa automática: $p < t1$. Análise manual: $t1 \leq p < t2$. Positiva automática: $p \geq t2$. As faixas aparecem sombreadas no gráfico. Os cortes são escolhidos na validação e aplicados ao teste sem novos ajustes.

As tabelas de saída trazem, para cada faixa, o percentual da população, a quantidade e a proporção de positivos e negativos. Trazem também as duas proporções de erro pedidas, cada uma com o denominador escrito:

- Positivos classificados automaticamente como negativos, sobre o total de positivos reais e sobre o total da faixa negativa automática.
- Negativos classificados automaticamente como positivos, sobre o total de negativos reais e sobre o total da faixa positiva automática.

3. Metodologia

O mesmo notebook roda os três domínios; muda apenas a configuração da base. A sequência segue a da aula: classe positiva, balanceamento, separação, representação, busca de hiperparâmetros, SHAP e avaliação, seguida dos pontos de corte. A semente 42 fixa todos os sorteios.

3.1 Balanceamento e escolha da métrica principal

A métrica principal, usada para otimizar e para escolher o melhor modelo, é o **F1 da classe positiva** nos três domínios.

- **SMS Spam (13,41% de spam):** um modelo que nunca aponta spam tem 86,59% de acurácia e é inútil. Os dois erros têm custo: spam que passa incomoda, e mensagem legítima bloqueada é pior. O F1 equilibra precisão e recall do spam.
- **Bank Marketing (11,52% de adesão):** a acurácia de referência é 88,48%. Interessa encontrar os aderentes (recall) sem desperdiçar ligações demais (precisão), exatamente o que o F1 combina.
- **Breast Cancer (37,26% de malignos):** a base é menos desbalanceada, mas os erros têm pesos diferentes. Um falso negativo atrasa o diagnóstico e é o erro grave. O F1 foi mantido para comparar os domínios, e o custo maior do falso negativo entra na escolha dos pontos de corte (seção 3.7).

3.2 Separação dos dados e validação

- `train_test_split` com 75% para desenvolvimento e 25% para teste, estratificado pela classe (`stratify=y`), para manter a proporção de positivos nos dois conjuntos.
- O teste fica reservado: só é usado na avaliação final e na aplicação das faixas.
- A validação é uma validação cruzada estratificada de 5 folds (`StratifiedKFold`, com embaralhamento) dentro do conjunto de desenvolvimento. Ela escolhe os hiperparâmetros, escolhe o melhor algoritmo e gera as probabilidades usadas para escolher os pontos de corte.

3.3 Pré-processamento e representação

- **SMS Spam:** TF-IDF da coluna de texto, com unigramas e bigramas, vocabulário de 500 termos e tokens formados só por letras (mesmos parâmetros da aula).
- **Bank Marketing:** One-Hot Encoding das 9 colunas categóricas e padronização (média 0, desvio 1) das 6 numéricas, totalizando 50 atributos.
- **Breast Cancer:** padronização das 30 medidas numéricas dos núcleos celulares.

As transformações ficam dentro de um `Pipeline` junto com o classificador. Assim, na validação cruzada, o TF-IDF, o One-Hot e a padronização são reajustados em cada fold usando apenas os dados de treino daquele fold, e nunca veem o fold de validação nem o teste.

3.4 Algoritmos e otimização de hiperparâmetros

Cada domínio compara três algoritmos de naturezas diferentes. Dois são comuns aos três domínios: Random Forest, um conjunto de árvores (não linear), e Regressão Logística (linear). O terceiro depende do tipo de dado:

- **Naive Bayes Multinomial** no spam: feito para frequências de palavras, não aceita os valores negativos gerados pela padronização das outras bases.
- **Gradient Boosting** no bank: árvores em sequência, fortes em dados tabulares com colunas categóricas e numéricas.
- **SVM com kernel RBF** no breast: adequado a bases pequenas e numéricas; fica lento em bases maiores.

Os hiperparâmetros foram otimizados com `RandomizedSearchCV`: 30 combinações sorteadas por algoritmo (20 no Naive Bayes, cuja grade só tem 20), avaliadas pelo F1 médio nos 5

folds. A grade do Random Forest é a da aula. Em Random Forest, Regressão Logística e SVM, `class_weight="balanced"` entrou como opção para lidar com o desbalanceamento. O melhor modelo de cada domínio é o de maior F1 médio na validação; depois ele é retreinado com todo o conjunto de desenvolvimento.

3.5 Avaliação no teste e construção das curvas

As métricas que dependem de uma decisão (acurácia, precisão, recall, F1 e matriz de confusão) usam **limiar de 0,50** sobre a probabilidade da classe positiva: probabilidade $\geq 0,50$ vira positivo. AUC-ROC, AUC-PR e AP usam as probabilidades, sem limiar fixo.

As curvas são construídas variando esse limiar de 1 até 0; em cada valor, as instâncias acima dele são classificadas como positivas e as taxas são recalculadas.

- **Curva ROC:** taxa de falsos positivos, $FP/(FP+TN)$, no eixo X, e taxa de verdadeiros positivos (recall), $TP/(TP+FN)$, no eixo Y. A AUC-ROC é a área sob essa curva e equivale à probabilidade de um positivo sorteado receber pontuação maior que um negativo sorteado. 0,5 é um classificador aleatório; 1,0 é separação perfeita.
- **Curva Precision-Recall:** recall no eixo X e precisão, $TP/(TP+FP)$, no eixo Y. A referência de um classificador aleatório é a proporção de positivos. Em bases desbalanceadas ela é mais exigente que a ROC, porque poucos falsos positivos já derrubam a precisão.

A área sob a curva PR foi calculada de duas formas, reportadas separadamente:

- **AUC-PR (trapezoidal):** integração pela regra do trapézio entre pontos consecutivos da curva (`sklearn.metrics.auc`).
- **Average Precision (AP):** média das precisões em cada limiar, ponderada pelo ganho de recall, sem interpolação (`average_precision_score`):

$$AP = \sum_n (R_n - R_{n-1}) \cdot P_n$$

3.6 Explicação com SHAP

O gráfico beeswarm do melhor modelo usa uma amostra aleatória do **conjunto de teste**, já transformada pelo pré-processamento. Cada ponto é uma instância; a posição é a contribuição da característica para a saída do modelo, e a cor é o valor da característica (vermelho alto, azul baixo). O explicador e a saída explicada dependem do modelo:

Modelo	Explicador	Saída explicada	Dados
Random Forest	<code>TreeExplainer</code>	Probabilidade da classe positiva	200 instâncias do teste
Regressão Logística	<code>LinearExplainer</code> (referência: 200 instâncias do treino)	Log-odds (margem) da classe positiva	200 instâncias do teste
SVM	Explicador por permutação (referência: 50 instâncias do treino)	Probabilidade da classe positiva	100 instâncias do teste

3.7 Escolha dos pontos de corte

Como a validação é cruzada, as probabilidades de validação são **out-of-fold** (`cross_val_predict`): cada instância do desenvolvimento recebe a probabilidade de um modelo que não a viu no treino. Sobre elas foi aplicada a regra:

- **t1** = maior limiar em que no máximo X% dos positivos reais ficam abaixo dele (erro da faixa negativa automática).
- **t2** = menor limiar em que no máximo Y% dos negativos reais ficam acima dele (erro da faixa positiva automática).

Com os erros limitados, as faixas automáticas ficam as maiores possíveis e a análise manual recebe o restante. As tolerâncias X e Y refletem o custo dos erros em cada domínio e são justificadas nas seções 4 a 6. Os cortes são aplicados ao teste sem nenhum ajuste.

4. Resultados — SMS Spam

A Regressão Logística foi o melhor modelo, com F1 de 0,9299 na validação e 0,9497 no teste. Com os cortes $t1 = 0,01$ e $t2 = 0,59$, 88,23% das mensagens de teste são decididas automaticamente, com uma única mensagem legítima bloqueada.

4.1 Comparação dos modelos

Algoritmo	F1 médio (validação)	Desvio entre folds	Melhores hiperparâmetros
Regressão Logística	0,9299	0,0149	C = 50, solver lbfgs, sem class_weight
Random Forest	0,9260	0,0187	700 árvores, max_depth 50, min_samples_split 10, min_samples_leaf 1, max_features sqrt, entropy, class_weight balanced
Naive Bayes Multinomial	0,8968	0,0168	alpha = 0,05, fit_prior True

Algoritmo (teste, limiar 0,50)	Acurácia	Precisão	Recall	F1	AUC-ROC	AUC-PR (trapezoidal)	AP
Regressão Logística	0,9871	0,9942	0,9091	0,9497	0,9839	0,9618	0,9618
Random Forest	0,9828	0,9939	0,8770	0,9318	0,9892	0,9682	0,9682
Naive Bayes Multinomial	0,9727	0,9745	0,8182	0,8895	0,9799	0,9401	0,9401


Matrizes de confusão no teste (TP / FP / FN / TN, em 187 spams e 1.206 hams): Regressão Logística 170 / 1 / 17 / 1.205; Random Forest 164 / 1 / 23 / 1.205; Naive Bayes 153 / 4 / 34 / 1.202.

- **Regressão Logística:** o maior F1 e o maior recall no limiar 0,50; quase não erra ao apontar spam (precisão 0,994).
- **Random Forest:** precisão igual, mas deixa passar mais spam (recall 0,877). Tem a maior AUC-ROC e AUC-PR, ou seja, ordena as mensagens um pouco melhor; a diferença aparece só fora do limiar de 0,50.
- **Naive Bayes:** o mais fraco em recall (0,818): perde cerca de 1 em cada 5 spams.

A diferença entre Regressão Logística e Random Forest na validação (0,0039) é menor que o desvio entre folds, então os dois estão praticamente empatados. A escolha seguiu a regra do trabalho: o maior F1 na validação, sem consultar o teste. A acurácia de 98,7% supera a referência de 86,6% (sempre "ham"), mas é o F1 que mostra a qualidade na classe spam.


4.2 Melhor modelo no teste

Matriz de confusão da Regressão Logística (limiar 0,50): **170 spams detectados, 17 spams que passaram, 1 mensagem legítima marcada como spam e 1.205 legítimas corretas**, em 1.393 mensagens de teste.



4.3 SHAP

Saída explicada: **log-odds da classe spam** da Regressão Logística. Dados: 200 mensagens sorteadas do conjunto de teste.



- **Aumentam a chance de spam** quando presentes (pontos vermelhos à direita): text, call, txt, reply, now, uk, free, www, ur e your. É o vocabulário de promoções e serviços por SMS ("call now", "reply", "txt", "free", links).
- **Diminuem a chance de spam:** i, me, my e that, típicos de conversa pessoal, e gt/lt, restos do marcador <#> que aparece em mensagens pessoais da base.
- Palavras muito frequentes, como to e a, também aparecem no topo. No modelo linear, a contribuição é o peso da palavra vezes o quanto ela se afasta da média; por serem comuns, elas empurram muitas mensagens um pouco.
- Valores baixos (azul) ficam perto de zero: como o TF-IDF é esparso, a ausência de uma palavra quase não muda a previsão; a presença, sim.

4.4 Pontos de corte e faixas de decisão


Tolerâncias: **até 3% dos spams** na faixa negativa automática e **até 0,5% das mensagens legítimas** na faixa positiva automática. Bloquear uma mensagem legítima é bem pior do que deixar passar um spam, por isso Y é muito menor que X.

Na validação (4.179 mensagens out-of-fold), a regra deu **t1 = 0,01 e t2 = 0,59**, com 15 de 560 spams (2,68%) abaixo de t1 e 18 de 3.619 legítimas (0,50%) acima de t2. O t1 é baixo porque a Regressão Logística com C = 50 gera probabilidades extremas: já em 0,05, 3,39% dos spams ficariam na faixa negativa.

Resultado no teste, com os cortes sem ajuste:

Faixa	Mensagens	% da população	Spam	Ham	% de spam na faixa	% de ham na faixa
Negativo automático (entregar), $p < 0,01$	1.061	76,17%	7	1.054	0,66%	99,34%
Análise manual, $0,01 \leq p < 0,59$	164	11,77%	13	151	7,93%	92,07%
Positivo automático (spam), $p \geq 0,59$	168	12,06%	167	1	99,40%	0,60%

Erro das decisões automáticas	Numerador	Denominador	Proporção
Spam classificado automaticamente como negativo	7	187 (total de spams reais)	3,74%
Spam classificado automaticamente como negativo	7	1.061 (total da faixa negativa automática)	0,66%
Ham classificado automaticamente como spam	1	1.206 (total de hams reais)	0,08%
Ham classificado automaticamente como spam	1	168 (total da faixa positiva automática)	0,60%



Política: 88,23% das mensagens são decididas sem intervenção, e só 1 das 1.206 mensagens legítimas foi bloqueada, o que atende à prioridade do domínio. A análise manual recebe 11,77% do volume, uma faixa de fato ambígua (7,93% de spam). No teste, 3,74% dos spams caíram na faixa de entrega automática, acima dos 3% da validação: com poucos spams no teste (187), uma ou duas mensagens mudam a taxa. É o erro mais barato do domínio e pode ser reduzido baixando a exigência de t1, ao custo de mais análise manual.

5. Resultados — Bank Marketing

O Random Forest foi o melhor modelo, com F1 de 0,4011 na validação e 0,3506 no teste. Sem a duração da ligação, o sinal disponível antes do contato é fraco (AUC-ROC 0,74), e a triagem automática cobre 16% dos clientes.

5.1 Comparação dos modelos

Algoritmo	F1 médio (validação)	Desvio entre folds	Melhores hiperparâmetros
Random Forest	0,4011	0,0482	200 árvores, max_depth 10, min_samples_split 10, min_samples_leaf 4, max_features log2, gini, class_weight balanced, subsample
Gradient Boosting	0,3359	0,0554	300 árvores, learning_rate 0,1, max_depth 3, subsample 0,85, min_samples_leaf 1
Regressão Logística	0,3324	0,0331	C = 1, solver liblinear, class_weight balanced

Algoritmo (teste, limiar 0,50)	Acurácia	Precisão	Recall	F1	AUC-ROC	AUC-PR (trapezoidal)	AP
Random Forest	0,8232	0,3034	0,4154	0,3506	0,7408	0,3206	0,3247
Regressão Logística	0,7065	0,2131	0,5769	0,3112	0,7254	0,2863	0,2914
Gradient Boosting	0,8859	0,5088	0,2231	0,3102	0,7429	0,3341	0,3403


Matrizes de confusão no teste (TP / FP / FN / TN, em 130 aderentes e 1.001 não-aderentes): Random Forest 54 / 124 / 76 / 877; Regressão Logística 75 / 277 / 55 / 724; Gradient Boosting 29 / 28 / 101 / 973.


- **Random Forest:** o melhor equilíbrio no limiar 0,50: encontra 41,5% dos aderentes e acerta 3 em cada 10 contatos que indica.
- **Regressão Logística:** com `class_weight` balanced, aponta muitos clientes como aderentes; tem o maior recall (0,577) e a menor precisão (0,213).
- **Gradient Boosting:** o oposto: é conservador no limiar 0,50 (recall 0,223, precisão 0,509). Tem a maior AUC-ROC e AUC-PR, ou seja, ordena os clientes tão bem quanto o Random Forest; só o limiar de 0,50 não é o melhor para ele.

As três AUC-ROC ficam entre 0,72 e 0,75 e as AUC-PR em torno de 0,3, quase o triplo da referência aleatória (0,115). O limite é da base, não do algoritmo: sem `duration`, sobram o perfil do cliente e o histórico de campanhas. A acurácia confirma por que ela não serve aqui: o Gradient Boosting tem 88,6%, praticamente a mesma do modelo que nunca prevê adesão (88,5%).

5.2 Melhor modelo no teste


Matriz de confusão do Random Forest (limiar 0,50): **54 aderentes encontrados, 76 aderentes perdidos, 124 contatos sem adesão e 877 não-aderentes corretos**, em 1.131 clientes de teste.





5.3 SHAP

Saída explicada: **probabilidade de adesão** prevista pelo Random Forest. Dados: 200 clientes sorteados do conjunto de teste.



- **Forma de contato:** `contact_unknown` = 1 (contato sem registro do meio) diminui a probabilidade; `contact_cellular` = 1 aumenta. É a característica mais relevante do modelo.
- **Histórico com o banco:** `poutcome_success` = 1 (adesão numa campanha anterior) é o maior aumento individual, de até +0,14, embora raro. `previous` alto (mais contatos em

campanhas anteriores) também aumenta.

- **Idade:** a maioria das idades tem efeito pequeno e negativo, mas idades altas aumentam bastante a chance, junto com `job_retired`.
- **Compromissos financeiros:** `housing_yes` (financiamento imobiliário) e `loan_yes` (empréstimo) diminuem; `housing_no` e `loan_no` aumentam.
- **Campanha e época:** `campaign` alto (muitas ligações nesta campanha) diminui; `month_may` diminui, e `month_oct` aumenta em poucos casos.

5.4 Pontos de corte e faixas de decisão


Neste domínio, as faixas viram ações de marketing: **não contatar**, **contato padrão** e **contato prioritário**. Tolerâncias: **até 2% dos aderentes** no grupo "não contatar" (perder um aderente custa uma venda) e **até 5% dos não-aderentes** no grupo prioritário (uma ligação prioritária sem retorno custa pouco).

Na validação (3.390 clientes out-of-fold), a regra deu **t1 = 0,17** e **t2 = 0,55**, com 6 de 391 aderentes (1,53%) abaixo de t1 e 146 de 2.999 não-aderentes (4,87%) acima de t2.

Resultado no teste, com os cortes sem ajuste:

Faixa	Clientes	% da população	Aderiram	Não aderiram	% de aderentes na faixa	% de não-aderentes na faixa
Não contatar, $p < 0,17$	71	6,28%	2	69	2,82%	97,18%
Contato padrão, $0,17 \leq p < 0,55$	950	84,00%	87	863	9,16%	90,84%
Contato prioritário, $p \geq 0,55$	110	9,73%	41	69	37,27%	62,73%

Erro das decisões automáticas	Numerador	Denominador	Proporção
Aderente classificado automaticamente como negativo	2	130 (total de aderentes reais)	1,54%
Aderente classificado automaticamente como negativo	2	71 (total da faixa "não contatar")	2,82%
Não-aderente classificado automaticamente como positivo	69	1.001 (total de não-aderentes reais)	6,89%
Não-aderente classificado automaticamente como positivo	69	110 (total da faixa prioritária)	62,73%



Política: o grupo prioritário tem 37,27% de adesão, 3,2 vezes a taxa geral de 11,5%, e concentra 41 dos 130 aderentes (31,5%) em menos de 10% dos clientes. O grupo "não contatar" libera 6,28% das ligações perdendo só 2 aderentes (1,54%). O contato padrão fica com 84% da base, com adesão de 9,16%, próxima da geral: é onde o modelo pouco acrescenta, e a campanha segue como antes. No teste, 6,89% dos não-aderentes caíram no grupo prioritário, acima dos 5% da validação, mas é o erro de menor custo. O limite desta política é o sinal fraco da base: não há corte que automatize muito mais sem perder aderentes.

6. Resultados — Breast Cancer Wisconsin

O SVM com kernel RBF foi o melhor modelo, com F1 de 0,9747 na validação e 0,9608 no teste, sem nenhum falso positivo. Com os cortes $t1 = 0,06$ e $t2 = 0,68$, 88,12% dos exames de teste são decididos automaticamente, com 1 tumor maligno na faixa "provável benigno".

6.1 Comparação dos modelos

Algoritmo	F1 médio (validação)	Desvio entre folds	Melhores hiperparâmetros
SVM (RBF)	0,9747	0,0126	$C = 5$, gamma auto, sem class_weight
Regressão Logística	0,9675	0,0234	$C = 0,5$, solver liblinear, sem class_weight
Random Forest	0,9518	0,0207	300 árvores, max_depth 30, min_samples_split 2, min_samples_leaf 2, max_features 0,3, entropy, class_weight balanced_subsample

Algoritmo (teste, limiar 0,50)	Acurácia	Precisão	Recall	F1	AUC-ROC	AUC-PR (trapezoidal)	AP
SVM (RBF)	0,9720	1,0000	0,9245	0,9608	0,9948	0,9925	0,9926
Regressão Logística	0,9790	1,0000	0,9434	0,9709	0,9973	0,9960	0,9960
Random Forest	0,9720	1,0000	0,9245	0,9608	0,9977	0,9965	0,9966


Matrizes de confusão no teste (TP / FP / FN / TN, em 53 malignos e 90 benignos): SVM 49 / 0 / 4 / 90; Regressão Logística 50 / 0 / 3 / 90; Random Forest 49 / 0 / 4 / 90.



- Os três modelos têm precisão de 1,000 no teste: nenhum tumor benigno foi apontado como maligno.
- A diferença está no recall: a Regressão Logística deixa passar 3 dos 53 malignos; SVM e Random Forest, 4.
- As AUC ficam acima de 0,99: as 30 medidas dos núcleos celulares separam quase perfeitamente as classes.

No teste, a Regressão Logística foi um pouco melhor que o SVM (um maligno a mais detectado), mas o melhor modelo é escolhido pela validação, e o teste só confirma o desempenho. Com 53 malignos no teste, um caso muda o recall em quase 2 pontos, então os três modelos são equivalentes nesta base.

6.2 Melhor modelo no teste

Matriz de confusão do SVM (limiar 0,50): **49 malignos detectados, 4 malignos não detectados, nenhum benigno classificado como maligno e 90 benignos corretos**, em 143 exames de teste.






6.3 SHAP

Saída explicada: **probabilidade de malignidade** prevista pelo SVM. Dados: 100 exames sorteados do conjunto de teste, com 50 exames do treino como referência do explicador por permutação.

SHAP Summary Plot — breast — SVM
saída explicada: probabilidade da classe positiva



- **Aumentam a probabilidade de malignidade** quando altas: `worst texture`, `worst concavity`, `mean concavity`, `worst radius`, `worst area`, `radius error`, `mean concave points` e `worst perimeter`. São medidas de tamanho, irregularidade da textura e concavidade do contorno dos núcleos, sobretudo nos piores valores de cada exame (`worst`).

- **Diminuem quando altas:** compactness error e texture error, medidas de variação dentro do exame.
- Valores baixos (azul) das medidas de tamanho e concavidade puxam para benigno, o que é coerente com núcleos menores e de contorno mais regular.

6.4 Pontos de corte e faixas de decisão


As faixas representam um fluxo clínico: **provável benigno, avaliação especializada e forte indicação maligna**. Tolerâncias: **até 1% dos malignos** em "provável benigno", porque um maligno sem investigação é o erro grave, e **até 1% dos benignos** em "forte indicação maligna", para ninguém seguir para tratamento por engano.

Na validação (426 exames out-of-fold), a regra deu **t1 = 0,06 e t2 = 0,68**, com 1 de 159 malignos (0,63%) abaixo de t1 e 2 de 267 benignos (0,75%) acima de t2.

Resultado no teste, com os cortes sem ajuste:

Faixa	Exames	% da população	Malignos	Benignos	% de malignos na faixa	% de benignos na faixa
Provável benigno, $p < 0,06$	77	53,85%	1	76	1,30%	98,70%
Avaliação especializada, $0,06 \leq p < 0,68$	17	11,89%	3	14	17,65%	82,35%
Forte indicação maligna, $p \geq 0,68$	49	34,27%	49	0	100,00%	0,00%

Erro das decisões automáticas	Numerador	Denominador	Proporção
Maligno classificado automaticamente como negativo	1	53 (total de malignos reais)	1,89%
Maligno classificado automaticamente como negativo	1	77 (total da faixa "provável benigno")	1,30%
Benigno classificado automaticamente como positivo	0	90 (total de benignos reais)	0,00%
Benigno classificado automaticamente como positivo	0	49 (total da faixa "forte indicação maligna")	0,00%



Política: 88,12% dos exames recebem uma indicação automática, sem nenhum benigno na faixa de forte indicação maligna. A avaliação especializada recebe 11,89% dos exames, justamente os ambíguos (17,65% de malignos). O risco residual é 1 maligno em 53 (1,89%) na faixa "provável benigno". Em uso real, a triagem não substituiria o acompanhamento médico, e a equipe clínica decidiria se esse risco é aceitável ou se t1 deve ser ainda menor, com mais exames na avaliação especializada.

7. Comparação entre domínios e conclusões

O quanto as classes se separam decidiu o resultado mais do que o algoritmo. Onde a separação é alta (spam e breast), a triagem automatiza 88% dos casos com erros baixos; no bank, o sinal fraco limita tanto o F1 quanto a cobertura.

Domínio	Positivos	Melhor modelo	F1 (teste)	AUC-ROC	AP	t1 / t2	Cobertura automática	Positivos na faixa negativa	Negativos na faixa positiva
SMS Spam	13,41%	Regressão Logística	0,950	0,984	0,962	0,01 / 0,59	88,23%	3,74% (7/187)	0,08% (1/1.206)
Bank Marketing	11,52%	Random Forest	0,351	0,741	0,325	0,17 / 0,55	16,01%	1,54% (2/130)	6,89% (69/1.001)
Breast Cancer	37,26%	SVM (RBF)	0,961	0,995	0,993	0,06 / 0,68	88,12%	1,89% (1/53)	0,00% (0/90)

- **Acurácia engana em bases desbalanceadas.** No bank, um modelo com 88,6% de acurácia encontrou só 22% dos aderentes. O F1, a AUC-PR e a AP foram as métricas que distinguiram os modelos.
- **Não há algoritmo vencedor em todos os domínios.** A Regressão Logística venceu no texto, o Random Forest no tabular misto e o SVM na base numérica pequena. No

spam e no breast, o segundo colocado ficou a menos de um desvio entre folds do primeiro; no bank, o Random Forest venceu com folga.

- **Escolher pela validação evita viés de teste.** No spam e no breast, outro modelo foi um pouco melhor no teste, mas trocar o modelo depois de ver o teste tornaria a avaliação final otimista.
- **O pré-processamento dentro do Pipeline** garantiu que TF-IDF, One-Hot e padronização nunca vissem o fold de validação nem o teste.
- **Os pontos de corte transformam probabilidade em política.** As tolerâncias de cada domínio levaram a faixas diferentes: proteger mensagens legítimas no spam, concentrar aderentes no bank e não deixar malignos sem investigação no breast.

Limitações. Os resultados vêm de uma única divisão treino/teste; em bases pequenas, como o teste do breast (53 malignos), um caso muda as taxas em quase 2 pontos. As taxas de erro das faixas no teste ficaram próximas, mas nem sempre abaixo, das tolerâncias da validação (spam e bank). O bank usa a amostra de 10% da base (4.521 de 45.211 clientes); os números podem mudar na base completa.

8. Entregáveis e instruções de execução

Integrantes da equipe: a preencher.

Arquivo	Conteúdo
A2_notebook_unico_estilo_aula.ipynb	Código-fonte: programa da Parte 1 e modelagem da Parte 2 para as três bases
SMSSpamCollection.csv	Base SMS Spam (separador: tabulação)
bank.csv	Base Bank Marketing (separador: ponto e vírgula)
breast_cancer_wisconsin.csv	Base Breast Cancer Wisconsin (separador: vírgula)
Este relatório	Metodologia, resultados, gráficos e conclusões

Execução no Google Colab:

1. Em colab.research.google.com, abrir **Arquivo** → **Fazer upload de notebook** e escolher o notebook.
2. Arrastar os três CSVs para o painel **Arquivos** (ícone de pasta, à esquerda).
3. Na célula de configuração, escolher a base em `BASE_ESCOLHIDA` ("spam", "bank" ou "breast") e manter `EXECUCAO_RAPIDA = False`.
4. Usar **Ambiente de execução** → **Executar tudo**. No Colab gratuito, a execução leva cerca de 10 minutos no spam, 4 no bank e 2 no breast.
5. Repetir para as outras duas bases.

Execução local: Python 3.11 ou mais recente, com `pip install pandas numpy scikit-learn matplotlib shap jinja2 ipykernel`, e os três CSVs na mesma pasta do notebook. Os resultados deste relatório foram gerados com scikit-learn 1.8, pandas 3.0 e shap 0.51.

`EXECUCAO_RAPIDA = True` reduz a busca de hiperparâmetros para demonstrações (cerca de 1 minuto por base), mas altera os resultados; os números deste relatório são do modo normal.

9. Referências

- ALMEIDA, T.; HIDALGO, J. [SMS Spam Collection](#). UCI Machine Learning Repository, 2011. DOI: 10.24432/C5CC84. Licença CC BY 4.0.
- MORO, S.; RITA, P.; CORTEZ, P. [Bank Marketing](#). UCI Machine Learning Repository, 2014. DOI: 10.24432/C5K306. Licença CC BY 4.0.
- WOLBERG, W.; MANGASARIAN, O.; STREET, N.; STREET, W. [Breast Cancer Wisconsin \(Diagnostic\)](#). UCI Machine Learning Repository, 1993. DOI: 10.24432/C5DW2B. Licença CC BY 4.0.
- Bibliotecas: scikit-learn (modelos, pipelines, validação e métricas), shap (explicações), pandas, numpy e matplotlib.